

Indicador de cambios de tendencia de activos

Catriel Bartezaghi, Joaquin Luengo.

Inteligencia Computacional 2022, Ingeniería en Informática, FICH-UNL

Tutor: Jose Tomás Molas.

Resumen—

El objetivo principal del análisis bursátil, consiste en obtener información relevante sobre instrumentos financieros que sirva de ayuda en las tomas de decisiones de inversión. El avance tecnológico y la gran cantidad de información disponible permite desarrollar programas que faciliten ésta tarea.

A partir de ello surge el siguiente trabajo, el cual consiste en el desarrollo de una herramienta que permita predecir la tendencia de precio a futuro de diferentes activos, a partir del comportamiento de precio anteriores del mismo, utilizando redes neuronales.

Palabras claves—Trading, Redes Neuronales, MLP, LSTM, Análisis de activos.

I. INTRODUCCIÓN

Históricamente ha existido en un gran número de personas interés en la compra y venta de distintos activos con la finalidad de obtener beneficios económicos en un plazo de tiempo determinado. Por ello, surge el interrogante de cuál es el momento oportuno para adquirir o desprenderse de un activo. A partir de esta premisa, surgen distintas metodologías de análisis, dos de las más importantes son el *análisis fundamental* [1] y el *análisis técnico* [2].

En cuanto al análisis fundamental, pretende determinar el valor auténtico o intrínseco del activo, a partir de las distintas variables que influyen en su precio, lo que supone es un indicador del rendimiento futuro que se espera del activo. Por otro lado, se encuentra el análisis técnico, el cual se centra en el análisis del precio del activo y el volumen negociado, además de los indicadores que surgen de estos, con el propósito de anticipar con mayor probabilidad cambios en la estructura del mercado. Es esta última metodología la que da como punto de partida al presente trabajo, el cual tiene por finalidad evaluar qué tanto se puede inferir en los movimientos futuros de precios, utilizando redes neuronales, a partir de información anterior del comportamiento del precio y volumen operado del activo.

II. RECOPIACIÓN DE DATOS

Los datos históricos referentes a precio y volumen de los activos, son obtenidos de forma gratuita a partir de la api de *yahoo finance* [3]. Los datos de interés son precio de apertura, precio de cierre, precio mínimo, precio máximo y volumen negociado. Estos datos se obtienen para el lapso de tiempo y temporalidad deseada. Luego, a partir de estos valores se calculan distintos indicadores técnicos, que serán los patrones de entrada utilizados para el entrenamiento de la red neuronal. Un indicador técnico supone la formulación de expresiones matemáticas y estadísticas con el objetivo de suavizar la

tendencia de los precios o intentar predecir cambios de tendencia de precios con la suficiente anticipación como para actuar adecuadamente. Para el cálculo de los indicadores se utilizó la librería *pandas_ta*, la cual está basada en la librería *TA-Lib* [4].

A continuación se detalla los indicadores utilizados.

1) *EMA[5]*: La Media Móvil Exponencial (Exponential Moving Average) es un tipo de media móvil, que asigna una ponderación diferente a cada precio. Este cálculo favorece a los precios más recientes al otorgarles un peso mayor y reduciendo de manera exponencial según se retrocede en el tiempo. (ecuación 3)

SMA: El valor de la media móvil se calcula tomando los precios de cierre de un periodo determinado. Luego se suman cada uno de ellos, y el resultado de dicha suma se divide entre la cantidad de periodos tomados (ecuación 1)

$$SMA = \sum P(n) / N \quad (1)$$

P = valor del periodo

N = cantidad de periodos seleccionados

Calcular el multiplicador para ponderar la EMA: Este factor está determinado por el número de periodos de la EMA. Por lo que para su cálculo, se divide 2 entre la cantidad de periodos tomados más 1 (ecuación 2)

$$Multiplicador = [2 / (N + 1)] \quad (2)$$

$$EMA(n) = [PC(n) - EMA(n - 1)] * Mult + EMA(n - 1) \quad (3)$$

PC = Precio Cierre

Mult = Multiplicador

2) *RSI (Índice de Fuerza Relativa)[6]*: El RSI es un indicador de tipo oscilador que refleja la fuerza relativa de los movimientos alcistas, en comparación con los movimientos bajistas.

Mide la relación entre los movimientos ascendentes y descendentes, y normaliza el cálculo para que el índice fluctúe en un rango de 0 a 100.

La fórmula RSI tiene en cuenta dos ecuaciones que intervienen en la resolución de la fórmula. La ecuación del

primer componente obtiene el valor de fuerza relativa inicial (RS) (ecuación 4), que es la media de los cierres alcistas por encima de la media de los cierres bajistas, a lo largo de un periodo "N" representado en el siguiente cálculo

$$RS = EMA \text{ Alcista} / EMA \text{ Bajista} \quad (4)$$

EMA Alcista = Media móvil exponencial de 'N' periodos alcistas

EMA Bajista = Media móvil exponencial de 'N' periodos bajista

El valor del indicador RSI se calcula indexando el indicador a 100 utilizando la siguiente fórmula (ecuación 5):

$$RSI = 100 - \left(\frac{100}{1 + RS} \right) \quad (5)$$

3) ADX (Average Directional Index) [7]: El indicador ADX mide la fuerza de una tendencia independientemente de su dirección. (ecuación 6).

Se suele utilizar junto al indicador direccional positivo (DM+) e indicador direccional negativo (DM-).

Para el DM+ a partir de dos velas colindantes, cuando la vela actual hace un máximo superior a la anterior, el movimiento direccional será positivo y se obtiene la distancia entre estos dos máximos.

En el caso del DM- toma como referencia los mínimos. Con lo cual, cuando la vela actual hace un mínimo inferior a la vela anterior, se obtiene un movimiento direccional negativo.

Cuando el DM+ supera a DM- la tendencia será positiva.

En cambio cuando el DM- es mayor al DM+ la tendencia será bajista.

$$ADX = \frac{DMP - DMN}{DMP + DMN} * 100 \quad (ecuación 6)$$

4) MACD (Moving Average Convergence Divergence)[8]: Se utiliza para medir la robustez del movimiento del precio, señala, en cada momento, la diferencia entre el valor de dos medias móviles con diferente periodo de tiempo calculado.

Se emplean dos medias móviles: una exponencial con un periodo de tiempo corto en el cálculo y otra media móvil exponencial con una periodicidad media. Normalmente, para la media corta se emplean 12 periodos (estos pueden ser sesiones diarias, semanas, meses, horas, etc.) y, para la otra media, 26 periodos (ecuación 7)

$$MACD = EMA(12) - EMA(26) \quad (7)$$

La línea señal (MACDs), no es más que una media móvil de la primera (concretamente una EMA9, una exponencial de 9 periodos) y que se irá cruzando cada poco tiempo con la línea principal.

El histograma de MACD (MACDh) mide la distancia entre las dos curvas de MACD.

5) PSAR[9]: Parabolic SAR o parada y retroceso parabólicos, es un indicador técnico que se utiliza para pronosticar posibles giros de tendencia o continuaciones en un mercado subyacente.

El cálculo del Parabolic SAR es diferente según se utilice durante una tendencia al alza (ecuación 8) o a la baja (ecuación 9).

$$T. \text{ alza} = PSAR(n - 1) + AF(n - 1) * (EP(n - 1) - PSAR(n - 1)) \quad (8)$$

$$T. \text{ baja} = PSAR(n - 1) + AF(n - 1) * (PSAR(n - 1) - EP(n - 1)) \quad (9)$$

En este cálculo, el EP (extreme point) se refiere a los puntos más altos y más bajos de la dirección de la tendencia, y que se actualiza cada vez que se alcanza un nuevo EP. AF es la abreviatura del factor de aceleración (acceleration factor) es una constante de 0,02, que aumenta en 0,02 cada vez que se alcanza un nuevo EP, con un máximo de 0,20.

III. PROPUESTA DE SOLUCIÓN

A. Dataset

Como el objetivo de este trabajo es desarrollar un indicador técnico que dé información sobre cambio de tendencias en los activos con valores entre 0 y 1, es necesario cuantificar las tendencias en el precio. Cuando el precio se encuentra por encima de la media, el precio está en tendencia alcista, de lo contrario la tendencia es bajista. Partiendo de esta definición, es posible realizar una comparación entre la media y los precios de cierre y determinar en cuántos periodos estuvo el precio por encima de la media en un determinado lapso de tiempo. Con esta idea se generarán las salidas deseadas con las que se entrenará la red neuronal, por lo que el dataset para entrenamiento de la red tendrá la siguiente estructura:

- Entradas: Para cada patrón de entrada, se tomará una ventana de n intervalos anteriores y se obtendrán los valores de los indicadores en esos n intervalos.

De manera que si por ejemplo, se trabaja en intervalos de un día y se define una ventana de 10 valores, se tendrán 10 valores de entrada por cada indicador. Los valores de todos los indicadores son normalizados entre 0 y 1.

- Salidas: Para cada patrón de entrada se tendrá una única salida, la cual resulta del siguiente cálculo:

$$Yd(i) = \frac{\text{count}(\text{Price}[i : i+m] > EMA[i : i+m])}{m}$$

Es decir, se toma una ventana de m días posteriores y se realiza un conteo de cuantos valores estuvieron por encima de la media. En este caso se utilizó una media exponencial de 20 periodos.

De esta manera, tanto para la entradas como las salidas, se realiza el corrimiento de la ventana en 1 lugar, y se calculan los siguientes patrones de entrada y salida deseada.

En la figura 1, se puede visualizar un ejemplo de ventana de días sobre el cual se calcula la entrada (X) a partir de los valores de los indicadores en 10 días anteriores. En azul, la ventana sobre la que se calcula la única salida (yd) a partir de 5 valores de precio posteriores. Mientras que en verde, la gráfica de la media exponencial utilizada.

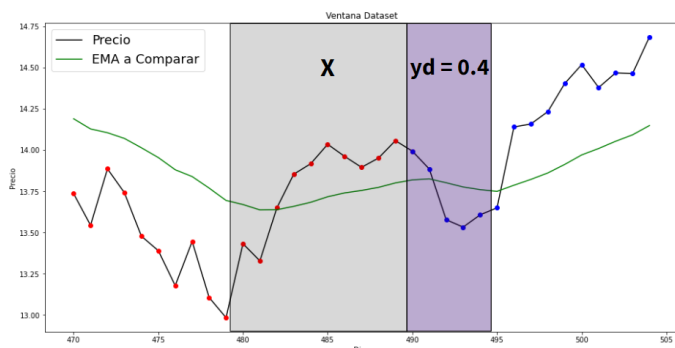


Fig.1 Ventanas para armado del dataset

B. Métodos

Para el aprendizaje de los datos se utilizaron dos modelos de redes neuronales por separado, Perceptrón Multicapa (MLP) y Long Short Term Memory (LSTM). Para la implementación de los modelos en *Python* [10] se utilizó la biblioteca de aprendizaje automático de código abierto *Pytorch* [11].

- 1) MLP: Para la implementación de esta red se utilizaron 3000 épocas, 100 neuronas en la capa oculta y una sola neurona en la capa de salida. En ambas capas se utilizó la función sigmoidea. Con respecto al cálculo del error se utilizó el error cuadrático medio provisto por la librería, además se aprovechó el optimizador Adam para la actualización de los parámetros, también provisto por la librería, el cual hace uso más eficiente de los datos y requiere menos memoria. En este caso cada patrón de entrada cuenta con valores de 10 días anteriores y para el cálculo de la salida se utilizan 5 días siguientes. Estos parámetros fueron elegidos como óptimos después de realizar diferentes pruebas.
- 2) LSTM: Es una red neuronal recurrente (RNN) que tiene la capacidad de recordar un dato relevante y preservarlo por varios instantes de tiempo, es decir tiene memoria a corto y largo plazo, este tipo de redes son adecuadas para clasificar, procesar y hacer predicciones basado en datos de series temporales ya que puede haber retrasos de duración desconocida entre eventos importantes. Con respecto a esta implementación se utilizaron 500 épocas, 50

neuronas en la capa oculta y 2 capas. Como optimizador se utilizó el algoritmo Adam. A diferencia del modelo MLP, como entrada para el entrenamiento se utiliza solo los valores de un instante anterior y para el cálculo de la salida se utilizan 5 días siguientes. Estos parámetros son los que mejor resultaron, debido a que un número de épocas o neuronas mayor, conduce a salidas que oscilan demasiado o con valores fuera del rango $[0,1]$.

C. Entrenamiento y Testing

En este tipo de sistemas es importante considerar los últimos valores que tuvo el mercado. Además, la forma de utilización de este sistema, el inversor cuenta con toda la información pasada para predecir unas pocas salidas futuras de interés. Por lo que el entrenamiento y validación se realiza de la siguiente manera:

1. Se define una ventana de n valores con los que se comparará con la salida correcta. Por ejemplo, los últimos 300 días.
2. En la primera iteración, se realiza el entrenamiento con todos los valores anteriores a la ventana, para predecir k valores futuros.
3. Luego se incorporan las entradas correspondientes a esos k predichos anteriormente, y se vuelve a entrenar para predecir los k siguientes.
4. Se continúa de esta manera hasta predecir los n valores correspondientes a la ventana.

De esta manera, siempre se realizan predicciones con el máximo de información posible.

IV. RESULTADOS

En esta sección se presentan los resultados obtenidos con ambos modelos. Para ello se realiza una simulación de inversión, realizando compras y venta de acciones a partir de las salidas del modelo en la etapa de testeo.

Cuando la salida del indicador fue mayor o igual a 0.8 se efectuó una compra, colocando además una orden stop-loss a un precio 3% por debajo del de compra, la cual solo se ejecuta si el precio cae. Por otro lado, en caso de que la salida del indicador sea menor o igual a 0.3 se efectúa la venta.

Se utilizó un escenario que cuenta con tendencias alcistas y bajistas, para que los resultados no estén condicionados por la tendencia. Para la prueba del modelo se utilizaron datos de la empresa Apple desde la fecha 01-01-2010 hasta 20-10-2022, realizando predicciones de a 2 valores en los últimos 300 días.

LSTM

En la figura 2 se puede observar una comparación entre las salidas deseadas y predichas. Si bien, la salida del indicador presenta oscilaciones y en ocasiones tiene desfase, se ajusta de manera correcta. En la figura 3, se pueden observar las compras y ventas realizadas a partir de las salidas deseadas y predichas del modelo. Se puede notar, como debido al

desfase mencionado, genera señales de compra o venta un poco tardías.




Fig. 2 Comparación salidas deseadas y predecidas (LSTM)




Fig. 3 Compras y ventas en AAPL (LSTM)

Las operaciones realizadas arrojaron un 19,52 % de ganancias en 300 días, lo cual es un muy buen resultado, considerando que la inflación anual en dólares es de alrededor del 8%.

MLP

A diferencia del modelo LSTM, se puede notar que el desfase es un poco mayor, dando señales un poco más tardías.




Fig. 4 Comparación salidas deseadas y predecidas (MLP)




Fig. 5 Compras y ventas en AAPL (MLP)

Las operaciones realizadas arrojaron un 16 % de ganancias en 300 días, un buen resultado aunque menor al LSTM.

V. CONCLUSIONES

Si bien, aún es necesario realizar más pruebas, se puede notar una gran eficiencia en la detección de cambios de tendencia. En ambos modelos las salidas predecidas se aproximan bastante a las esperadas. Desde este punto de vista el resultado es muy bueno, por lo que puede ser útil como una herramienta más de apoyo para el inversor. Pero, como se observa en la simulación de inversión, ante cambios bruscos en el mercado, suele dar señales tardías que derivan en

pérdidas. Estos movimientos bruscos muchas veces se deben a cambios imposibles de anticipar desde el movimiento de los precios, como por ejemplo el crash ocurrido por la pandemia de COVID-19, cambios en la política macroeconómica, etc. por lo que es importante realizar en paralelo un análisis fundamental.

Como trabajo a futuro, en el corto plazo, puede ser interesante realizar un análisis sobre qué indicadores aportan mayor información en un determinado activo, además de un ajuste correcto de los parámetros de los indicadores de acuerdo a la volatilidad del precio del activo. Además, se puede inicializar los pesos de las redes con alguna configuración a partir del tipo de acción, de manera de reducir la aleatoriedad que tiene influencia en los resultados finales.

A largo plazo, se puede realizar un modelo de redes neuronales con un enfoque de análisis fundamental, que sirva de apoyo al modelo de este trabajo, de manera de cubrir las dos categorías del análisis bursátil clásico.

AGRADECIMIENTOS

El grupo agradece al docente Jose Tomas Molas y a todo el cuerpo de docentes de Inteligencia Computacional de la Facultad de Ingeniería y Ciencias Hídricas, por habernos guiado y darnos apoyo a lo largo de todo el cuatrimestre.

REFERENCIAS

- [1] Segal, T. (2022). Fundamental Analysis: Principles, Types, and How to Use It. Investopedia. www.investopedia.com/terms/f/fundamentalanalysis.asp
- [2] Hayes, A. (2022). Technical Analysis: What It Is and How to Use It in Investing. Investopedia. <https://www.investopedia.com/terms/t/technicalanalysis.asp>
- [3] Tran, M. (2018). API Documentation. Yahoo Finance. <https://python-yahoofinance.readthedocs.io/en/latest/api.html>
- [4] Benediktsson, J. TA-Lib Documentation. https://mrjbq7.github.io/ta-lib/doc_index.html
- [5] Garzon, E. ¿Qué es una Media Móvil Exponencial? Aprende a usar el indicador de trading EMA. <https://admiralmarkets.com/es/education/articles/forex-indicators/media-movil-exponencial>
- [6] Admirals. (2022) Indicador RSI | Qué es el RSI en bolsa y divergencias RSI. <https://admiralmarkets.com/es/education/articles/forex-indicators/como-sacar-beneficio-del-indicador-de-trading-rsi>
- [7] Garzón, E. (2022). Aprende a usar el Indicador ADX en MetaTrader 4 Ejemplo de Estrategia de Trading. <https://admiralmarkets.com/es/education/articles/forex-indicators/como-utiliza-r-indicador-adx-metatrader-4>
- [8] Avatrade. Estrategias de trading MACD. <https://www.avatrade.es/education/professional-trading-strategies/macd-trading-strategies>
- [9] Traget, T. (2022) Parabolic SAR: Puntos de la Tendencia. <https://libertex.org/es/blog/indicador-parabolic-sar>
- [10] Van Rossum, G. y Drake, F. (2009). Python 3 Reference Manual. Scotts Valley, CA: CreateSpace.
- [11] PyTorch Contributors. (2022). Pytorch Documentation. <https://pytorch.org/docs/stable/index.html#pytorch-documentation>